Nama: Andi Cleopatra Maryam Jamila

Nim: 1103213071

Classification model

```
# Install dan impor library
    !pip install xgboost
    import pandas as pd
    import numpy as np
    import matplotlib.pyplot as plt
    import seaborn as sns
    from sklearn.model_selection import train_test_split, GridSearchCV
    from sklearn.preprocessing import StandardScaler, LabelEncoder
    from sklearn.pipeline import Pipeline
    from sklearn.linear_model import LogisticRegression
    from sklearn.tree import DecisionTreeClassifier
    from sklearn.neighbors import KNeighborsClassifier
    from xgboost import XGBClassifier
    from sklearn.metrics import classification_report, accuracy_score, confusion_matrix
Requirement already satisfied: xgboost in /usr/local/lib/python3.10/dist-packages (2.1.2)
    Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from xgboost) (1.26.4)
    Requirement already satisfied: nvidia-nccl-cu12 in /usr/local/lib/python3.10/dist-packages (from xgboost) (2.23.4)
    Requirement already satisfied: scipy in /usr/local/lib/python3.10/dist-packages (from xgboost) (1.13.1)
```

Memasukkan library yang dibutuhkan dalam Classification model

Memuat Dataset

```
[81] # Menentukan kolom dengan nama yang sesuai
     columns = ['sepal length', 'sepal width', 'petal length', 'petal width', 'species']
[82] # Memuat dataset dengan header yang benar
     df = pd.read_csv("/content/sample_data/iris.data", header=None, names=columns)
     # Menampilkan lima data pertama
     df.head()
₹
         sepal_length sepal_width petal_length petal_width
                                                                   species
      0
                   5.1
                                 3.5
                                                             0.2 Iris-setosa
      1
                   4.9
                                 3.0
                                               1.4
                                                             0.2 Iris-setosa
      2
                   4.7
                                 3.2
                                               1.3
                                                             0.2 Iris-setosa
      3
                   4.6
                                 3.1
                                               1.5
                                                             0.2 Iris-setosa
                   5.0
                                 3.6
                                                             0.2 Iris-setosa
```

Menentukan kolom dengan nama yang sesuai, kemudian memasukkan dataset untuk dibaca, dan menampilkan 5 data pertama

```
[83] # Cek nama kolom dan data
     print(df.columns)
     print(df.head())
     Index(['sepal_length', 'sepal_width', 'petal_length', 'petal_width',
            'species'],
           dtype='object')
        sepal length sepal width
                                   petal length
                                                  petal width
                                                                   species
     0
                 5.1
                              3.5
                                                          0.2
                                                               Iris-setosa
                 4.9
     1
                              3.0
                                             1.4
                                                          0.2 Iris-setosa
     2
                 4.7
                              3.2
                                             1.3
                                                          0.2 Iris-setosa
     3
                 4.6
                              3.1
                                             1.5
                                                          0.2 Iris-setosa
     4
                 5.0
                              3.6
                                             1.4
                                                          0.2 Iris-setosa
```

Penjelasan: Data iris.csv berisi fitur sepal dan petal beserta label kelas spesies.

Mengecek nama kolom dan data

** Explanatory Data Analysis (EDA)**

a) Statistik Deskriptif


```
[84] # Statistik deskriptif
     df.describe()
₹
             sepal_length sepal_width petal_length petal_width
               150.000000
                             150.000000
      count
                                           150.000000
                                                         150.000000
      mean
                 5.843333
                               3.054000
                                             3.758667
                                                           1.198667
                 0.828066
                               0.433594
                                             1.764420
                                                           0.763161
       std
       min
                 4.300000
                               2.000000
                                             1.000000
                                                           0.100000
       25%
                 5.100000
                               2.800000
                                              1.600000
                                                           0.300000
       50%
                 5.800000
                               3.000000
                                              4.350000
                                                           1.300000
      75%
                 6.400000
                               3.300000
                                              5.100000
                                                           1.800000
                 7.900000
                               4.400000
                                                           2.500000
      max
                                              6.900000
```

Memberikan ringkasan statistik deskriptif untuk setiap kolom numerik dalam dataset, seperti nilai ratarata (mean), standar deviasi (std), nilai minimum (min), kuartil (25%, 50%, 75%), dan nilai maksimum

(max). b) Cek Missing Value

[85]	df.isnull().	sum	()	
		0		
	sepal_length	0		
	sepal_width	0		
	petal_length	0		
	petal_width	0		
	species	0		
	dtype: int64			

Mengidentifikasi jumlah nilai kosong (missing values) dalam setiap kolom dataset.




Membuat scatter plot untuk semua pasangan fitur dalam dataset, dikelompokkan berdasarkan variabel species.

Data Visualization

a) Heatmap Korelasi

```
[87] # Menghapus kolom 'species' sebelum menghitung korelasi
correlation = df.drop('species', axis=1).corr()
```

Menghitung matriks korelasi antar fitur numerik, dengan menghapus kolom species karena bukan numerik.



Insights: Menunjukkan hubungan kuat antara panjang dan lebar petal.

Memvisualisasikan matriks korelasi menggunakan heatmap.

```
sns.countplot(data=df, x='species')
plt.title("Distribusi Spesies")
plt.show()

Distribusi Spesies

50 -

40 -

10 -

10 -
```

Insights: Setiap kelas memiliki distribusi vang seimbang.

Iris-setosa

Membuat bar chart untuk menunjukkan jumlah data di setiap kategori species.

Iris-virginica

Iris-versicolor

species

Preprocessing

a) Pisahkan Fitur dan Target

```
[90] X = df.drop("species", axis=1)
y = df["species"]
```

b) Split Data

```
[91] X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

c) Standardisasi Fitur

```
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)
```

- Memisahkan dataset menjadi fitur independen (X) dan target yang akan diprediksi (y).
- Membagi data menjadi data pelatihan (80%) dan data pengujian (20%).
- Mengubah data agar memiliki rata-rata 0 dan standar deviasi 1 (standar)

Pipeline Model

a) Logistic Regression

- Membuat pipeline untuk Logistic Regression. Pipeline membantu menyusun alur kerja machine learning secara modular.
- Mencari parameter terbaik untuk Logistic Regression menggunakan GridSearchCV.
- Menampilkan kombinasi parameter terbaik berdasarkan skor validasi.

Decision Tree

- Membuat pipeline untuk Decision Tree Classifier.
- Mencari parameter terbaik untuk Decision Tree.

- Membuat pipeline untuk k-Nearest Neighbors (k-NN).
- Mencari parameter terbaik untuk k-NN.

d) XGBoost

```
[ [ from xgboost import XGBClassifier
      # Menggunakan XGBClassifier tanpa parameter use_label_encoder
      xgb_model = XGBClassifier()
[103]
      # Menyusun pipeline (pastikan tanpa use label encoder)
      pipeline_xgb = Pipeline([
          ('scaler', StandardScaler()), # Jika perlu scaling
          ('classifier', xgb_model)
      ])
[104] # Hyperparameter grid tanpa 'use_label_encoder'
      'classifier_learning_rate': [0.01, 0.1, 0.2],
          'classifier__n_estimators': [50, 100, 200]
[111] # Menerapkan GridSearchCV
      grid_xgb = GridSearchCV(pipeline_xgb, param_grid_xgb, cv=5)
      grid_xgb.fit(X_train, y train_encoded)
      print(f"Best Params XGBoost: {grid_xgb.best_params_}")
  🚁 Best Params XGBoost: {'classifier_learning_rate': 0.01, 'classifier_max_depth': 3, 'classifier__n_estimators': 200}
```

- Membuat pipeline untuk model XGBoost.
- Mencari parameter terbaik untuk XGBoost.